

1 統計

1.1 相関係数 (correlation coefficient)

分散 n 個の資料 x_1, x_2, \dots, x_n の分散 σ_x^2 は

$$\sigma_x^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$$

と定義する。偏差の2乗和。

共分散 2変量 (x, y) をもつ n 個の資料 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ における共分散 σ_{xy} は

$$\sigma_{xy} = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

(ただし、 $\bar{x} = \frac{1}{n} \sum x_i, \bar{y} = \frac{1}{n} \sum y_i$)

と定義する。 x の偏差と y の偏差の積の平均。

相関係数の定義 2変量 (x, y) を持つ n 個の資料を $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ とする。

このとき、相関係数 r は

$$r = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

と定義される。 x と y の共分散を標準偏差の積で割る。

また、分子の n と x と y の標準偏差をかけることで生まれる n が打ち消しあうので以下の定義も可能

$$\begin{aligned} r &= \frac{\frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2} \sqrt{\frac{1}{n} \sum (y_i - \bar{y})^2}} \\ &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \end{aligned}$$

相関係数の絶対値が1以下の証明 相関係数 r が $-1 \leq r \leq 1$ となることを証明する。

まず

$$\begin{array}{lll} x_i - \bar{x} = a_i & y_i - \bar{y} = b_i & a_i b_i = c_i \\ \sum a_i^2 = A & \sum b_i^2 = B & \sum a_i b_i = C \end{array}$$

とおくと

$$-1 \leq r \leq 1$$

$$-1 \leq \frac{C}{\sqrt{A}\sqrt{B}} \leq 1$$

$$-c \leq x \leq c \leftrightarrow x^2 \leq c^2 \text{なので}$$

$$\left(\frac{C}{\sqrt{A}\sqrt{B}}\right)^2 \leq 1^2$$

$$\frac{C^2}{AB} \leq 1$$

$$C^2 \leq AB \quad (AB \geq 0)$$

$$C^2 - AB \leq 0$$

$$AB - C^2 \geq 0$$

のように変形できるのでこれを証明する

ここで以下の関数を考える

$$\begin{aligned} f(x) &= \sum (a_i x - b_i)^2 \\ &= \sum (a_i^2 x^2 - 2a_i b_i x + b_i^2) \\ &= \sum a_i^2 x^2 - 2\left(\sum a_i b_i\right) + \sum b_i^2 \\ &= Ax^2 - 2Cx + B \end{aligned}$$

これを平方完成すると

$$\begin{aligned} &= A\left(x^2 - \frac{2C}{A}x\right) + B \\ &= A\left\{\left(x - \frac{C}{A}\right)^2\right\} - \frac{C^2}{A} + B \\ &= A\left\{\left(x - \frac{C}{A}\right)^2\right\} + \frac{AB - C^2}{A} \end{aligned}$$

$f(x)$ は2乗の和なので、 $f(x) \geq 0$

$x = \frac{C}{A}$ のとき $f(x)$ は最小値 $\frac{AB - C^2}{A}$ をとるので

$$\frac{AB - C^2}{A} \geq 0$$

$$AB - C^2 \geq 0 \quad (A \geq 0)$$

となり、証明できた。